

简书

首页

下载APP

会员

IT技术

搜索



抽奖

Aa

beta

登录

注册



跟着代码理解BERT中的优化器AdamW (AdamWeightDecayOptimizer)



菜菜鑫

关注



0.24

2020.04.11 10:53:47 字数 1,951 阅读 13,894

引言

最近依旧在做命名实体识别的任务，一直在想如何能在保证效率的前提下，提升BERT+BiLSTM+CRF这个主流模型的准确率。“达观杯”的获奖方案中有的队伍使用了Lookahead+Adam的优化器，所以我也打算从优化器的方向入手看看能否有效果的提升。本以为BERT中使用的是用烂了的Adam，一看源码发现是重写的优化器，叫AdamWeightDecayOptimizer，本来Adam都没太搞懂，又来一个WeightDecay，一起学一下吧。

热门故事

[超A女霸总在线撩夫](#)[我把老板当金库，老板把我当老婆](#)[男神学长求放过，你的节操掉了](#)[情深见于微](#)

推荐阅读

[一文搞懂对比学习\(Contrastive Learning\)](#)

阅读 125

[第六讲：流体模拟- 流体力学基础](#)

阅读 344

[MachineLearning 10. 癌症诊断机器学习之神经网络 \(Neural Network\)](#)

阅读 1,354

[正则化，归一化，标准化的区别与联系](#)

阅读 107

[还得回家](#)

阅读 41,525

写下你的评论...



评论0



赞7



简书

首页

下载APP

会员

IT技术

搜索



抽奖

beta

登录

注册

重衰减在大部分情况下并不等价，只在SGD优化的情况下是等价的。而大多数框架中对于Adam+L2正则使用的是权重衰减的方式，两者不能混为一谈。

先回顾一下Adam优化器的前置知识，并结合源码理解Adam优化器，再来看AdamW与之的不同之处，本文依旧不会有复杂的数学公式，相关实现以python代码的形式展示。

Adam前置知识

1. 梯度下降法

最基本的优化方法，沿着负梯度的方向更新参数，实现如下：

```
1 | # 梯度下降法
2 | x += - learning_rate * dx
```

其中learning_rate是**超参数**代表学习率，被更新的**变量**为x，其梯度为dx，梯度->位置，很好理解。

但是梯度下降法相关的优化方法容易产生震荡，且容易被困在鞍点，迟迟不能到达全局最优值。

2. 动量法



如何广告推广



国内船运查询

男神学长求放过，你的节操掉了
情深见于微

推荐阅读

一文搞懂对比学习(Contrastive Learning)

阅读 125

第六讲：流体模拟- 流体力学基础

阅读 344

MachineLearning 10. 癌症诊断机器学习之神经网络 (Neural Network)

阅读 1,354

正则化，归一化，标准化的区别与联系

阅读 107

还得回家

阅读 41,525

写下你的评论...

评论0

赞7

简书

首页

下载APP

会员

IT技术

搜索



登录

注册

现如下:

```
1 # 动量法
2 v = mu * v - learning_rate * dx # 梯度影响速度
3 x += v # 速度决定位置
```

变量 v 的初始值被定为0, **超参数** μ 在优化过程中被视为动量, 其物理意义可以视为摩擦系数, 加入的这一项, 可以使得梯度方向不变的维度上速度变快, 梯度方向有所改变的维度上的更新速度变慢, 这样就可以加快收敛并减小震荡。和之前不同的是梯度不会直接对位置造成影响, 梯度->速度->位置。

3. RMSprop

RMSprop是一种自适应学习率方法, 依旧是基于梯度对位置进行更新。为了消除梯度下降中的摆动, 加入了梯度平方的指数加权平均。梯度大的指数加权平均就大, 梯度小的指数加权平均就小, 保证各维度的梯度都在一个良机, 进而减少摆动。

关于指数加权平均的通俗理解可以参考<https://zhuanlan.zhihu.com/p/29895933>

```
1 # RMSprop
2 cache = decay_rate * cache + (1 - decay_rate) * dx**2 # 梯度平方的指数加权平均
3 x += - learning_rate * dx / (np.sqrt(cache) + eps) # 基于梯度更新
```



如何广告推广



国内船运查询

男神学长求放过, 你的节操掉了
情深见于微

推荐阅读

一文搞懂对比学习(Contrastive Learning)

阅读 125

第六讲: 流体模拟- 流体力学基础

阅读 344

MachineLearning 10. 癌症诊断机器学习之神经网络 (Neural Network)

阅读 1,354

正则化, 归一化, 标准化的区别与联系

阅读 107

还得回家

阅读 41,525

写下你的评论...

评论0

赞7

简书

首页

下载APP

会员

IT技术

搜索



登录

注册

还有一些其他效果较好的优化器，由于这些前置知识已经足够理解Adam了，所以在此不做过多介绍。

Adam

Adam可以看做动量法和RMSprop的结合

```
1 # Adam
2 m = beta1*m + (1-beta1)*dx
3 v = beta2*v + (1-beta2)*(dx**2)
4 x += - learning_rate * m / (np.sqrt(v) + eps)
```

对于m和v的处理，同样使用了指数加权平均。相比于RMSprop，梯度换为了平滑的m，而cache的处理基本没有变化。**超参数**beta1和beta2的初始值接近于1，因此，计算出的偏差项接近于0。

AdamW

AdamW是在Adam+L2正则化的基础上进行改进的算法。

使用Adam优化带L2正则的损失并不有效。如果引入L2正则项，在计算梯度的时候会加上对正则项求梯度的结果。那么如果本身比较大的一些权重对应的梯度也会比较大，由于Adam计算步骤



如何广告推广



国内船运查询

男神学长求放过，你的节操掉了
情深见于微

推荐阅读

一文搞懂对比学习(Contrastive Learning)

阅读 125

第六讲：流体模拟- 流体力学基础

阅读 344

MachineLearning 10. 癌症诊断机器学习之神经网络 (Neural Network)

阅读 1,354

正则化，归一化，标准化的区别与联系

阅读 107

还得回家

阅读 41,525

写下你的评论...

评论0

赞7

简书

首页

下载APP

会员

IT技术

搜索



抽奖

beta

登录

注册

Algorithm 2 Adam with L₂ regularization and Adam with decoupled weight decay (AdamW)

```

1: given  $\alpha = 0.001, \beta_1 = 0.9, \beta_2 = 0.999, \epsilon = 10^{-8}, \lambda \in \mathbb{R}$ 
2: initialize time step  $t \leftarrow 0$ , parameter vector  $\theta_{t=0} \in \mathbb{R}^n$ , first moment vector  $m_{t=0} \leftarrow \mathbf{0}$ , second moment vector  $v_{t=0} \leftarrow \mathbf{0}$ , schedule multiplier  $\eta_{t=0} \in \mathbb{R}$ 
3: repeat
4:    $t \leftarrow t + 1$ 
5:    $\nabla f_t(\theta_{t-1}) \leftarrow \text{SelectBatch}(\theta_{t-1})$   $\triangleright$  select batch and return the corresponding gradient
6:    $g_t \leftarrow \nabla f_t(\theta_{t-1}) + \lambda \theta_{t-1}$ 
7:    $m_t \leftarrow \beta_1 m_{t-1} + (1 - \beta_1) g_t$   $\triangleright$  here and below all operations are element-wise
8:    $v_t \leftarrow \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$ 
9:    $\hat{m}_t \leftarrow m_t / (1 - \beta_1^t)$   $\triangleright \beta_1$  is taken to the power of  $t$ 
10:   $\hat{v}_t \leftarrow v_t / (1 - \beta_2^t)$   $\triangleright \beta_2$  is taken to the power of  $t$ 
11:   $\eta_t \leftarrow \text{SetScheduleMultiplier}(t)$   $\triangleright$  can be fixed, decay, or also be used for warm restarts
12:   $\theta_t \leftarrow \theta_{t-1} - \eta_t \left( \alpha \hat{m}_t / (\sqrt{\hat{v}_t} + \epsilon) + \lambda \theta_{t-1} \right)$ 
13: until stopping criterion is met
14: return optimized parameters  $\theta_t$ 

```

Adam+L2 VS AdamW

图片中红色是传统的Adam+L2 regularization的方式，绿色是Adam+weightdecay的方式。可以看出两个方法的区别仅在于“系数乘以上一步参数值”这一项的位置。再结合代码来看一下AdamW的具体实现。

以下代码来自<https://github.com/macany/BERT-BiLSTM-CRF->



如何广告推广



国内船运查询

男神学长求放过，你的节操掉了

情深见于微

推荐阅读

一文搞懂对比学习(Contrastive Learning)

阅读 125

第六讲：流体模拟- 流体力学基础

阅读 344

MachineLearning 10. 癌症诊断机器学习之神经网络 (Neural Network)

阅读 1,354

正则化，归一化，标准化的区别与联系

阅读 107

还得回家

阅读 41,525

写下你的评论...

评论0

赞7

简书

首页

下载APP

会员

IT技术

搜索



抽奖



登录

注册

param_name 是 Adam 中使用的，也就是 Adam 中已有的部分对应的代码，weightdecay 这一步是发生在 Adam 中需要被更新的参数 update 计算之后，并且在乘以学习率 learning_rate 之前，这和图片中的伪代码的计算顺序是完全一致的。总之一句话，如果使用了 weightdecay 就不必再使用 L2 正则化了。

```
1 # m = beta1*m + (1-beta1)*dx
2 next_m = (tf.multiply(self.beta_1, m) + tf.multiply(1.0 - self.beta_1, grad))
3 # v = beta2*v + (1-beta2)*(dx**2)
4 next_v = (tf.multiply(self.beta_2, v) + tf.multiply(1.0 - self.beta_2, tf.square(grad)))
5 # m / (np.sqrt(v) + eps)
6 update = next_m / (tf.sqrt(next_v) + self.epsilon)
7 # Just adding the square of the weights to the loss function is *not*
8 # the correct way of using L2 regularization/weight decay with Adam,
9 # since that will interact with the m and v parameters in strange ways.
10 #
11 # Instead we want ot decay the weights in a manner that doesn't interact
12 # with the m/v parameters. This is equivalent to adding the square
13 # of the weights to the loss with plain (non-momentum) SGD.
14 if self._do_use_weight_decay(param_name):
15     update += self.weight_decay_rate * param
16 update_with_lr = self.learning_rate * update
17 # x += - learning_rate * m / (np.sqrt(v) + eps)
18 next_param = param - update_with_lr
```

原有的英文注释中也解释了 Adam 和传统 Adam+L2 正则化的差异，好了到这里应该能理解 Adam 了，并且也能理解 AdamW 在 Adam 上的改进了。



如何广告推广



国内船运查询

男神学长求放过，你的节操掉了
情深见于微

推荐阅读

一文搞懂对比学习(Contrastive Learning)

阅读 125

第六讲：流体模拟- 流体力学基础

阅读 344

MachineLearning 10. 癌症诊断机器学习之神经网络 (Neural Network)

阅读 1,354

正则化，归一化，标准化的区别与联系

阅读 107

还得回家

阅读 41,525

写下你的评论...

评论0

赞7

简书

首页

下载APP

会员

IT技术

搜索



抽奖



登录

注册

在BERT中引入优化器的源码中有这样一句注释

```
1 | # It is recommended that you use this optimizer for fine tuning, since this
2 | # is how the model was trained (note that the Adam m/v variables are NOT
3 | # loaded from init_checkpoint.)
```

也就是说在微调BERT的时候强烈建议使用AdamW优化器。在自己的NER数据集上使用6层BERT, AdamW能得到98%左右的F1值, 我尝试使用了RAdam, Lookahead+RAdam和Lookahead+AdamW, 还有Ranger, 得到的效果都非常差, 要不就0的F1值, 要不就是30%左右, 好像完全没有效果。

项目参考源码: <https://github.com/macanv/BERT-BiLSTM-CRF-NER>

RAdam,Lookahead:<https://github.com/lifeiteng/Optimizers>

<https://github.com/michaelrzhang/lookahead>

Ranger:https://github.com/jyhengcoder/Ranger_tensorflow

请大神解答一下, 为什么达观杯有的队伍用了Lookahead取得了较好的效果(可能在训练BERT模型时就用了Lookahead?)。那是什么原因导致的我实验中微调官方提供的BERT模型时Lookahead和RAdam效果不好, 是超参数的问题还是预训练好的BERT模型不适用于这些优化器那?



如何广告推广



国内船运查询

男神学长求放过, 你的节操掉了
情深见于微

推荐阅读

一文搞懂对比学习(Contrastive Learning)

阅读 125

第六讲: 流体模拟- 流体力学基础

阅读 344

MachineLearning 10. 癌症诊断机器学习之神经网络 (Neural Network)

阅读 1,354

正则化, 归一化, 标准化的区别与联系

阅读 107

还得回家

阅读 41,525

写下你的评论...

评论0

赞7

简书

首页

下载APP

会员

IT技术

搜索



抽奖

beta

登录

注册

<https://www.cnblogs.com/gaoyuanda/p/6342334.html><https://zhuanlan.zhihu.com/p/63982470><https://zhuanlan.zhihu.com/p/38945390>

7人点赞 >



NLP




更多精彩内容，就在简书APP



"小礼物走一走，来简书关注我"

赞赏支持

还没有人赞赏，支持一下



菜菜鑫

总资产0.724 共写了9426字 获得31个赞 共29个粉丝

关注

写下你的评论...

评论0

赞7



如何广告推广



国内船运查询

男神学长求放过，你的节操掉了
情深见于微

| 推荐阅读

一文搞懂对比学习(Contrastive Learning)

阅读 125

第六讲：流体模拟- 流体力学基础

阅读 344

MachineLearning 10. 癌症诊断机器学习之神经网络 (Neural Network)

阅读 1,354

正则化，归一化，标准化的区别与联系

阅读 107

还得回家

阅读 41,525

简书

首页

下载APP

会员

IT技术

搜索



beta

登录

注册

全部评论 0 只看作者

按时间倒序 按时间正序

被以下专题收入，发现更多相似内容



NER



NLP&NLU


推荐阅读

《Scikit-Learn与TensorFlow机器学习实用指南》第11章 训练...
(第一部分 机器学习基础) 第01章 机器学习概览第02章 一个完整的机器学习项目 (上) 第02章 一个完整的机器学习...



SeanCheney 阅读 1,991 评论 0 赞 17

更多精彩内容>



详解梯度下降优化算法

1. 文章 An overview of gradient descent optimization algo...



如何广告推广



国内船运查询

男神学长求放过，你的节操掉了
情深见于微

推荐阅读

一文搞懂对比学习(Contrastive Learning)

阅读 125

第六讲：流体模拟- 流体力学基础

阅读 344

MachineLearning 10. 癌症诊断机器学习之神经网络 (Neural Network)

阅读 1,354

正则化，归一化，标准化的区别与联系

阅读 107

还得回家

阅读 41,525

写下你的评论...

评论0

赞7

简书

首页

下载APP

会员

IT技术

搜索



beta

登录

注册

www.dlworld.cn 听说你了解深度学习最常用的学习算法：Adam优化算法？-深度学习世界深度学习常常需要...



hzyido 阅读 46,313 评论 0 赞 24

神经网络与深度学习

1 前馈神经网络 在神经网络中，输入层与输出层之间的层称为隐含层或隐层 (hidden layer)，隐层和输出层的...



TSW1995 阅读 597 评论 0 赞 0

谁的青春不迷茫？

吃过晚饭后，在美团上买了张《谁的青春不迷茫》的电影票，便骑车到了影城。在去的路上，我就一直在想，谁的青春不迷茫？只...



车小沫 阅读 501 评论 3 赞 5



11月6日

今天白天可以说又是虚度一天，晚上哥来电话说给我找了新的单位，明天可能要等电话面试，我什么都不会心里有点慌，微信和支...



兆之 阅读 101 评论 0 赞 0

```
1  $\beta_1$  and  $\beta_2$  to the power  $t$ .  
2  $\alpha$ : Step size  
3  $\beta_1, \beta_2 \in [0, 1]$ : Exponential decay rates for the moment estimates  
4  $f(\theta)$ : Stochastic objective function with parameters  $\theta$   
5  $\theta_0$ : Initial parameter vector  
6 Initialize 1st moment vector  
7 Initialize 2nd moment vector  
8 Initialize (moment)  
9 not converged do  
10  $t \leftarrow t + 1$   
11  $\nabla_{\theta} f(\theta_{t-1})$  (Get gradients w.r.t. stochastic objective at timestep  $t$ )  
12  $\tilde{m}_t \leftarrow \beta_1 m_{t-1} + (1 - \beta_1) \cdot g_t$  (Update biased first moment estimate)  
13  $\tilde{v}_t \leftarrow \beta_2 v_{t-1} + (1 - \beta_2) \cdot g_t^2$  (Update biased second raw moment estimate)  
14  $\hat{m}_t \leftarrow \tilde{m}_t / (1 - \beta_1^t)$  (Compute bias-corrected first moment estimate)  
15  $\hat{v}_t \leftarrow \tilde{v}_t / (1 - \beta_2^t)$  (Compute bias-corrected second raw moment estimate)  
16  $\theta_t \leftarrow \theta_{t-1} - \alpha \cdot \hat{m}_t / (\sqrt{\hat{v}_t} + \epsilon)$  (Update parameters)  
17  $\theta_t$  (Resulting parameters)
```



如何广告推广



国内船运查询

男神学长求放过，你的节操掉了
情深见于微

推荐阅读

一文搞懂对比学习(Contrastive Learning)

阅读 125

第六讲：流体模拟- 流体力学基础

阅读 344

MachineLearning 10. 癌症诊断机器学习之神经网络 (Neural Network)

阅读 1,354

正则化，归一化，标准化的区别与联系

阅读 107

还得回家

阅读 41,525

写下你的评论...

评论0

赞7

简书

首页

下载APP

会员

IT技术

搜索



beta

登录

注册



如何广告推广




国内船运查询

排位

对于小学班主任来说，排座位是班级一项必不可少又看似十分简单而又很难的工作。因为要让每个学生都满意又适应学生发展...



行走的教育 阅读 239 评论 0 赞 4



【剽悍牛人进化营变现模块】-如何实现财务自由

博多.舍费尔《财务自由之路》看完了，财务自由是我们大部分人的梦想。这本书给出了财务自由的人所使用的不同维度的思考和...



heatheryip 阅读 119 评论 1 赞 2

印象笔记与得到笔记可以同步。

今天安装了印象笔记。因为印象笔记可以同步得到笔记，平时记在得到里面的课程笔记。都是按老师划分目录的。所以只要记住老...



Bob邵红华 阅读 636 评论 0 赞 1

写下你的评论...

评论0

赞7



如何广告推广



国内船运查询

男神学长求放过，你的节操掉了

情深见于微

推荐阅读

一文搞懂对比学习(Contrastive Learning)

阅读 125

第六讲：流体模拟- 流体力学基础

阅读 344

MachineLearning 10. 癌症诊断机器学习之神经网络 (Neural Network)

阅读 1,354

正则化，归一化，标准化的区别与联系

阅读 107

还得回家

阅读 41,525



写下你的评论...

评论0 赞7