



ChatGPT 智慧分類與 訓練文本建構系統


從主題挖掘、圖譜建模到高品質
文本清洗的端到端解決方案



系統總覽：四大核心自動化引擎



模組一 | 全球重大主題挖掘



嚴密的命名公約與分類粒度

正確示範：前綴繼承法



使用半形連字號「-」分隔「繼承的父類別前綴」與「新增下層細項」，細項內單字維持空格。


錯誤示範：語意碎裂



禁止過度碎裂化。底層類別不得僅是單一新聞標題或短期情節，必須具備持續蒐集多篇資料的獨立價值。

模組二 | 混合式分類圖譜橋接 (Bridge Nodes)

類別圖譜同時服務「結構建模」與「向下展開檢索」。當跨越不同分類維度時，嚴禁建立直接捷徑 (Shortcuts)。



橋接節點必須具備穩定的主題意義與未來擴充性，避免為連接單一葉節點而建立無效的人工節點。

【核心矩陣】圖譜關係邊定義

結構型直接包含 (Structural Contains)	檢索型主題包含 (Retrieval Contains)	非階層語意關係 (Semantic Edge)
• 屬性 絕對的本體論上下位關係 (Direct Subtype)。 • 標記 contains • 適用 A 是 B 的直接類型、地區、或事件分支。	• 屬性 具備長期穩定檢索價值的資訊分支。 • 標記 contains + 備註加上「新增檢索型主題包含」。 • 限制 不是單純的因果、影響或偶發共同出現。	• 屬性 具明確方向性與獨立建模價值的方法/影響關係。 • 標記 限定沿用既有明確詞彙 (如 `is affected by`、`can be improved with`)。 ⚠ 嚴禁 絕對禁止使用語意模糊的 `related_to`、 `associated_with`。

【案例解析】實戰圖譜視覺化

1


既有層級重用

優先整合並橋接現有架構
(如 `IR Affairs` /
`US Military`)。

3

交叉父類別與橋接

透過多父類別 (Multi-
parent) 滿足不同維度的
向下檢索需求，避免產生
邏輯循環。



2

新增階層式路徑

建立具有嚴謹前綴繼承的
結構型包含邊 (實線)。

模組三 | 階層式資料蒐集漏斗




目標每類別每語言
 $A + B1 \geq 100$
份單篇直接來源。
(A類占比 $\geq 80\%$ 為優化基準)。

【決策樹】 文本補充與降級機制



核心精神：「錯標比缺資料更嚴重」 (Mislabeling is worse than missing data)。不得在仍可取得 A 或 B1 時，大量產生細微改詞的 B2 搜尋結果來湊數。若連上層類別都無法可靠支持，必須果斷剔除。

標籤精確度：Primary 與 Secondary 判定



1. 判定原則

- 分類以「文章主要敘事」為準。出現單一關鍵字、背景介紹或歷史回顧，不足以構成獨立分類價值。

2. Primary Label


- 單一標籤任務下，每篇文章必須歸入一個最主要類別。

3. Secondary Candidate


- 其餘具實質內容的次要主題，列為次要候選標籤，供後續檢索與分析。

⚠ 嚴格禁令：絕對禁止機械式複製同一篇文章到多個兄弟類別來充數，防止單一標籤訓練集被污染。

模組四 | 深度清校與雜訊過濾



複雜文本的完美切割 (P1/P2 切割邏輯)



何時觸發切割？

- 原始檔實際混入多篇文章。
- 單篇文章包含多個篇幅完整、可獨立閱讀且對應不同既有分類的主題段落。

切割規範 (Execution Flow)

- **命名規則**：強制追加後綴，例如 `news_001_P1.txt` (嚴禁使用 `.txt_P1` 或 `-part1``)。
- **上下文保留**：允許保留辨識文章所需的共同標題或簡短背景。
- **精準歸檔**：每個片段直接存入對應的 `#T#[類別名稱]` 目錄。原始混合檔強制排除，避免重複污染。

嚴密追蹤：100% 可追溯的清校紀錄

文本清校處理紀錄.csv

原始檔名	處理動作	輸出檔名	是否切割	處理原因
report_2023_Q4.pdf	正文抓取成功	report_2023_Q4_A.txt	否	核驗符合底層標籤，保留完整正文。
mixed_topics_v1.docx	切割	mixed_topics_v1_P1.txt, mixed_topics_v1_P2.txt	是	原始檔實際混入多篇 文章，依主題分割。
legacy_data_draft.txt	剔除	-	否	內容不符，無法識別 有效段落。
overview_summary.html	重新歸類	overview_summary_A.txt	否	內容更適合兄弟類別 (金融 -> 科技)。


B1 升級軌跡

- **Promoted To A (已轉 A)：**
正文抓取成功，核驗符合底層標籤。
- **Reclassified (已重新歸類)：**
內容更適合兄弟類別，轉移目錄。
- **Moved To Parent (已降至上層)：**
內容僅能支持寬泛概念，轉為上層
補充樣本。
- **Rejected (已剔除)：**
內容不符或抓取失敗。

核心規範：不得在沒有重新檢查正文的情況下，批次將 B1 升級為 A。每一個保留、移動、切割與排除都必須記錄具體原因，拒絕含糊描述。

最終交付架構與品質檢核


最終交付架構 (Final Deliverable Structure)



Final Quality Assurance (品質檢核)

- ✓ 所有 TXT 均為 UTF-8，不存在空白檔案。
- ✓ 目錄層級與 CSV 類別 Label 100% 吻合 (含大小寫與連字號)。
- ✓ B1/B2 未核驗資料絕無冒充 A 類樣本。
- ✓ 處理紀錄 CSV 涵蓋所有原始文本命運，無遺漏。

綜效：真正企業級的 NLP 訓練資料庫



透過 ChatGPT 代理人驅動，這不僅是一套執行規則，
而是一座確保持續進化、高度純淨的智慧資料工廠。